



**POLITECHNIKA  
RZESZOWSKA**  
im. IGNACEGO ŁUKASIEWICZA



**Wydział Matematyki i Fizyki Stosowanej**

Kierunek studiów:

Inżynieria i analiza danych, rok II, semestr IV



**Marcin Michno**  
164182

**SZEREGI CZASOWE**

**Projekt końcowy**

Rzeszów, 15 maja 2021 r.

## SPIS TREŚCI

Rozdział pierwszy – szereg z wyraźną sezonowością .....	4
1. Wprowadzenie do analizowanych danych.....	4
1) Informacje o ramce danych: .....	4
2) Przykładowe rekordy danych:.....	4
2. Utworzenie szeregów czasowych z średnimi: dziennymi, miesięcznymi, kwartalowymi (Po odpowiednim „wycięciu” potrzebnych danych, konwersji skali temperatur).....	4
3. Reprezentacja szeregu czasowego na różnego rodzaju wykresach.....	5
3) Wykresy z użyciem <code>xyplot()</code> .....	5
4) Wykresy panelowe .....	6
5) Wykresy sezonowe z użyciem <code>monthplot()</code> , <code>seasonplot()</code> .....	6
6) Wykresy pudełkowe .....	7
7) Wykresy rozrzutu wartości opóźnionych .....	8
8) Wykresy funkcji autokorelacji – <code>Acf</code> , cząstkowej autokorelacji – <code>Pacf</code> .....	9
9) Wygładzenie danych poprzez użycie średniej ruchomej .....	10
4. Dekompozycja przykładowych szeregów metodami: addytywną, multiplikatywną .....	10
5. Dekompozycje na podstawie modelu regresji: trend liniowy/wielomianowy, sezonowość, transformacja Boxa-Coxa .....	12
6. Eliminacja trendu i sezonowości z użyciem <code>decompose()</code> , wizualizacja rezultatu.....	15
7. Uczynienie szeregu stacjonarnym – eliminacja trendu, sezonowości poprzez różnicowanie i stabilizacja wariancji poprzez transformację Boxa-Coxa .....	16
8. Sprawdzenie stacjonarności otrzymanego szeregu .....	17
9. Wyznaczenie współczynników modelu autoregresji i porównanie dopasowania różnymi metodami estymacji .....	17
10. Wyznaczenie współczynników modelu ruchomej średniej z użyciem funkcji <code>Arima()</code> .....	18
11. Porównanie modelu ruchomej średniej z modelem autoregresji, analiza dobroci dopasowania.....	19
12. Wyznaczenie optymalnych modeli z wykorzystaniem funkcji <code>auto.arima()</code> , oraz ich porównanie na podstawie kryteriów dopasowania, wybór najlepszego .....	19
13. Test stacjonarności automatycznie dobranego modelu.....	20
14. Prognozowanie z wykorzystaniem metod naiwnych .....	21
10) Prognoza oparta na średniej .....	21
11) Prognoza po wyeliminowaniu sezonowości .....	21
12) Prognozowanie naiwne z użyciem funkcji <code>naive()</code> .....	22
13) Prognozowanie z użyciem funkcji <code>snaive()</code> .....	22
14) Prognozowanie naiwne z dryfem .....	23
Rozdział drugi – szereg z wyraźnym trendem .....	24

1. Wprowadzenie do analizowanych danych.....	24
1) Informacje o ramce danych:.....	24
2) Przykładowe rekordy danych:.....	24
2. Utworzenie szeregów czasowych z średnimi: dziennymi, miesięcznymi, kwartalowymi (Po odpowiednim „wycięciu” potrzebnych danych, interpolacji wartości brakujących) .....	24
3. Reprezentacja szeregu czasowego na różnego rodzaju wykresach.....	25
1) Wykres z użyciem <code>xyplot()</code> .....	25
2) Wykres panelowy .....	26
3) Wykres pudełkowy .....	26
4) Wykres rozrzutu wartości opóźnionych.....	27
5) Wykresy funkcji autokorelacji – <code>Acf</code> , częściowej autokorelacji – <code>Pacf</code> .....	27
6) Wygładzenie danych poprzez użycie średniej ruchomej .....	28
4. Dekompozycje na podstawie modelu regresji: trend liniowy/wielomianowy, transformacje Boxa-Coxa.....	29
5. Uczynienie szeregu stacjonarnym – eliminacja trendu, sezonowości poprzez różnicowanie i stabilizacja wariancji poprzez transformację Boxa-Coxa .....	30
6. Sprawdzenie stacjonarności otrzymanego szeregu .....	34
7. Wyznaczenie współczynników modelu autoregresji i porównanie dopasowania różnymi metodami estymacji .....	34
8. Wyznaczenie współczynników modelu ruchomej średniej z użyciem funkcji <code>Arima()</code> .....	35
9. Porównanie modelu ruchomej średniej z modelem autoregresji, analiza dobroci dopasowania.....	35
10. Wyznaczenie optymalnych modeli z wykorzystaniem funkcji <code>auto.arima()</code> , oraz ich porównanie na podstawie kryteriów dopasowania, wybór najlepszego .....	36
11. Test stacjonarności automatycznie dobranego modelu.....	37
12. Prognozowanie z wykorzystaniem metod naiwnych .....	38
1) Prognoza oparta na średniej.....	38
2) Prognozowanie naiwne z użyciem funkcji <code>naive()</code> .....	38
3) Prognozowanie z użyciem funkcji <code>snaive()</code> .....	39
4) Prognozowanie naiwne z dryfem.....	39

# Rozdział pierwszy – szereg z wyraźną sezonowością

## 1. Wprowadzenie do analizowanych danych

Dane z szeregu sezonowego zawierają średnie temperatury dzienne stolic wybranych państw na przestrzeni lat: 1995 - 2020. W projekcie tym analizowane będą wyłącznie te dotyczące Polski. Zostały one pobrane ze strony:

<https://www.kaggle.com/sudalairajkumar/daily-temperature-of-major-cities>

### 1) Informacje o ramce danych:

```
'data.frame': 2906327 obs. of 8 variables:
 $ Region      : chr "Africa" "Africa" "Africa" "Africa" ...
 $ Country     : chr "Algeria" "Algeria" "Algeria" "Algeria" ...
 $ State       : chr "" "" "" "" ...
 $ City        : chr "Algiers" "Algiers" "Algiers" "Algiers" ...
 $ Month       : int 1 1 1 1 1 1 1 1 1 ...
 $ Day         : int 1 2 3 4 5 6 7 8 9 10 ...
 $ Year        : int 1995 1995 1995 1995 1995 1995 1995 1995 1995 ...
 $ AvgTemperature: num 64.2 49.4 48.8 46.4 47.9 48.7 48.9 49.1 49 51.9 ...
```

Region	Country	State	City	Month
Length:2906327	Length:2906327	Length:2906327	Length:2906327	Min. : 1.000
Class :character	Class :character	Class :character	Class :character	1st Qu.: 3.000
Mode :character	Mode :character	Mode :character	Mode :character	Median : 6.000
				Mean : 6.469
				3rd Qu.: 9.000
				Max. :12.000

Day	Year	AvgTemperature
Min. : 0.00	Min. : 200	Min. : -99.0
1st Qu.: 8.00	1st Qu.:2001	1st Qu.: 45.8
Median :16.00	Median :2007	Median : 62.5
Mean :15.72	Mean :2007	Mean : 56.0
3rd Qu.:23.00	3rd Qu.:2013	3rd Qu.: 75.5
Max. :31.00	Max. :2020	Max. :110.0

### 2) Przykładowe rekordy danych:

Region	Country	State	City	Month	Day	Year	AvgTemperature
1 Africa	Algeria		Algiers	1	1	1995	64.2
2 Africa	Algeria		Algiers	1	2	1995	49.4
3 Africa	Algeria		Algiers	1	3	1995	48.8
4 Africa	Algeria		Algiers	1	4	1995	46.4
5 Africa	Algeria		Algiers	1	5	1995	47.9
6 Africa	Algeria		Algiers	1	6	1995	48.7

## 2. Utworzenie szeregów czasowych z średnimi: dziennymi, miesięcznymi, kwartalowymi (Po odpowiednim „wycięciu” potrzebnych danych, konwersji skali temperatur)

```
> ### wybór regionu i państwa dla analizy jego danych (np. "Europe", "Poland")
> sort(unique(my_data$Region))
[1] "Africa"
[3] "Australia/South Pacific"
[5] "Middle East"
[7] "South/Central America & Caribbean"
[9] "Asia"
[11] "Europe"
[13] "North America"


> sort(unique(my_data[chosenRows,]$Country))
[1] "Albania"
[5] "Bulgaria"
[9] "Denmark"
[13] "Germany"
[17] "Ireland"
[21] "Norway"
[25] "Russia"
[29] "Sweden"
[33] "United Kingdom"
[35] "Austria"
[37] "Croatia"
[39] "Finland"
[41] "Greece"
[43] "Italy"
[45] "Poland"
[47] "Serbia-Montenegro"
[49] "Switzerland"
[51] "Yugoslavia"
[53] "Belarus"
[55] "Cyprus"
[57] "France"
[59] "Hungary"
[61] "Latvia"
[63] "Portugal"
[65] "Slovakia"
[67] "The Netherlands"
[69] "Belgium"
[71] "Czech Republic"
[73] "Georgia"
[75] "Iceland"
[77] "Macedonia"
[79] "Romania"
[81] "Spain"
[83] "Ukraine"
```

```

### Utworze średnie dla miesięcy w danych latach dla większej ilości wykresów, ich przejrzystości
# Można zrobić podobnie dla lat w danym okresie, powstałaby jednak mała, niereprezentatywna próba
MonthTemp <- c()
for (i in unique(NData$Year)){
  for (j in unique(NData$Month)){
    value = mean(NData[[(NData[1:dim(NData)[1],2]==i) & (NData[1:dim(NData)[1],3]==j)],5), na.rm=TRUE)
    MonthTemp <- c(MonthTemp, value)
  }
}

### Utworzenie szeregu czasowego dla kwartałów w poszczególnych latach poprzez agregację danych miesięcznych
TimeSeriesIQ <- aggregate(TimeSeriesIM, nfrequency = 4, FUN = mean)


```




### 3. Reprezentacja szeregu czasowego na różnego rodzaju wykresach

#### 3) Wykresy z użyciem xyplot()


Średnie temperatury kwartalne w Polsce



Średnie temperatury miesięczne w Polsce

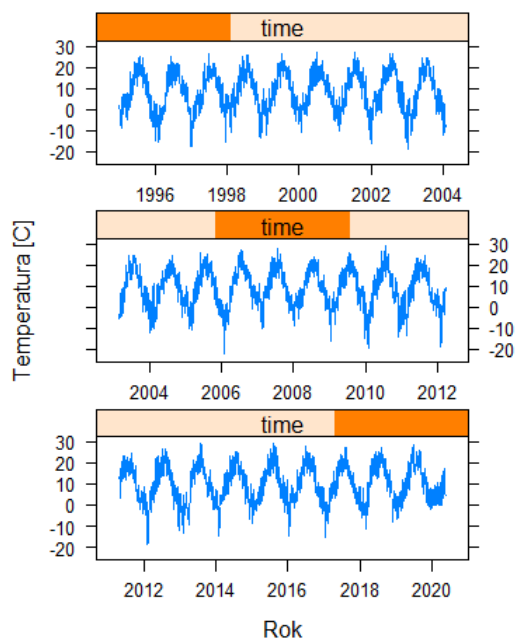


Średnie temperatury dzienne w Polsce

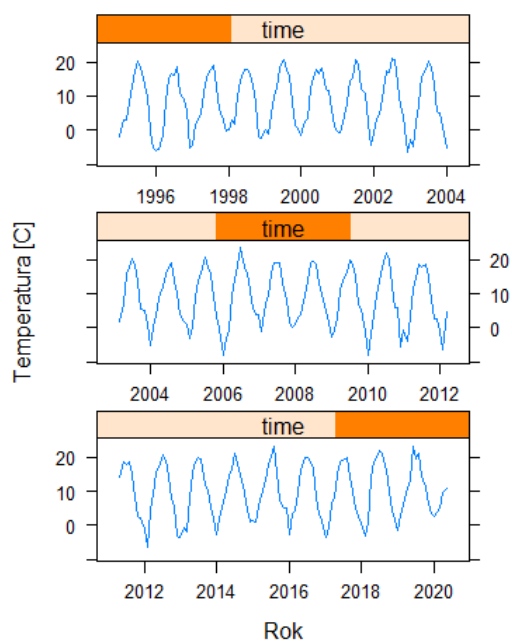


#### 4) Wykresy panelowe

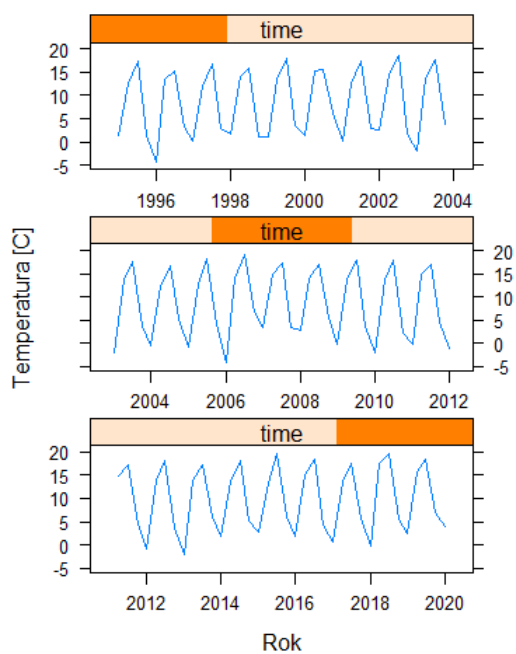
Średnie temperatury dzienne w Polsce




Średnie temperatury miesięczne w Polsce




Średnie temperatury kwartalne w Polsce




#### 5) Wykresy sezonowe z użyciem monthplot(), seasonplot()



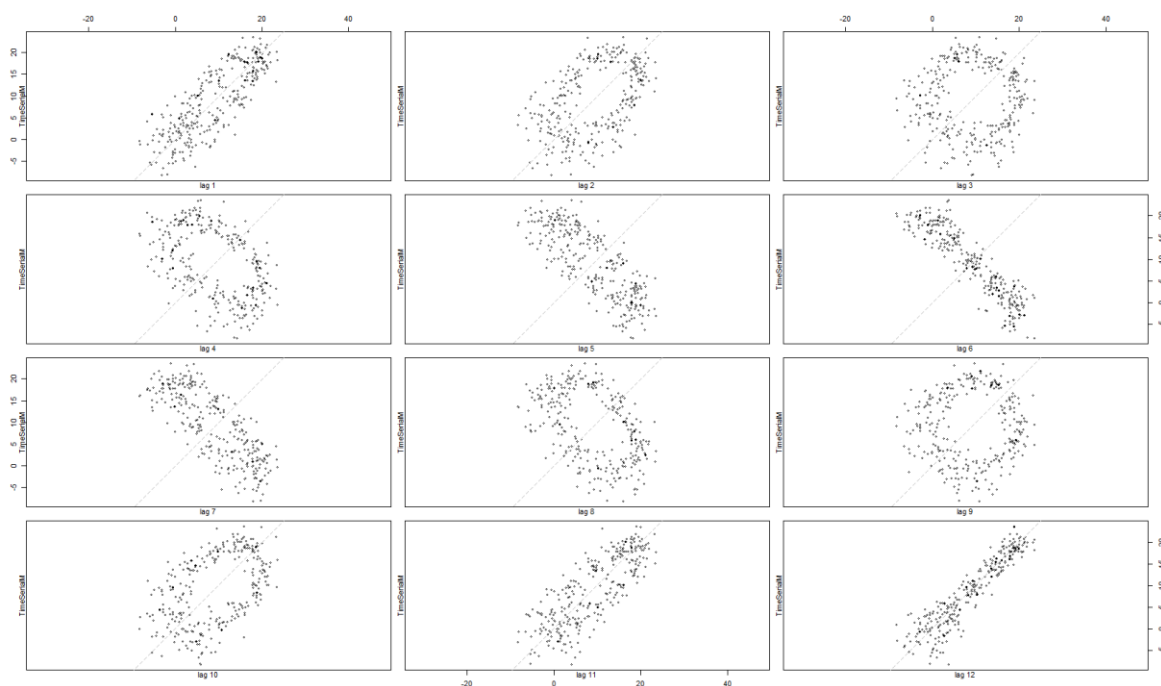


Widoczna jest duża różnorodność temperatur dziennych w poszczególnych latach, jednak zawsze także sezonowość.

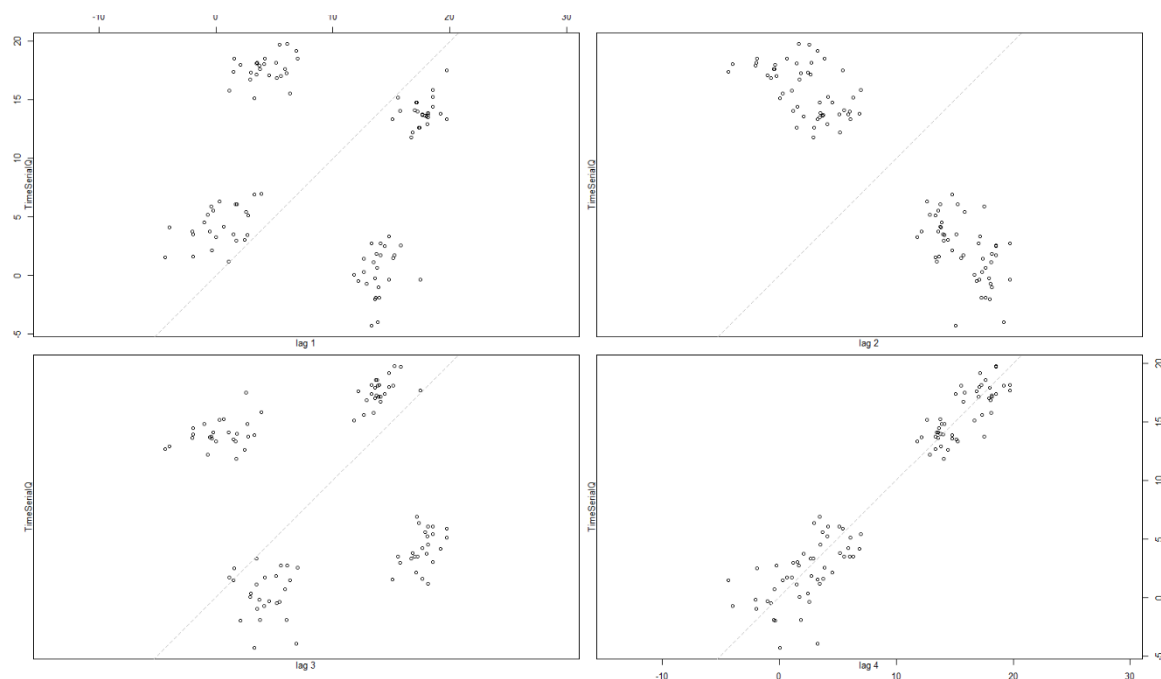
## 6) Wykresy pudełkowe



## 7) Wykresy rozrzutu wartości opóźnionych



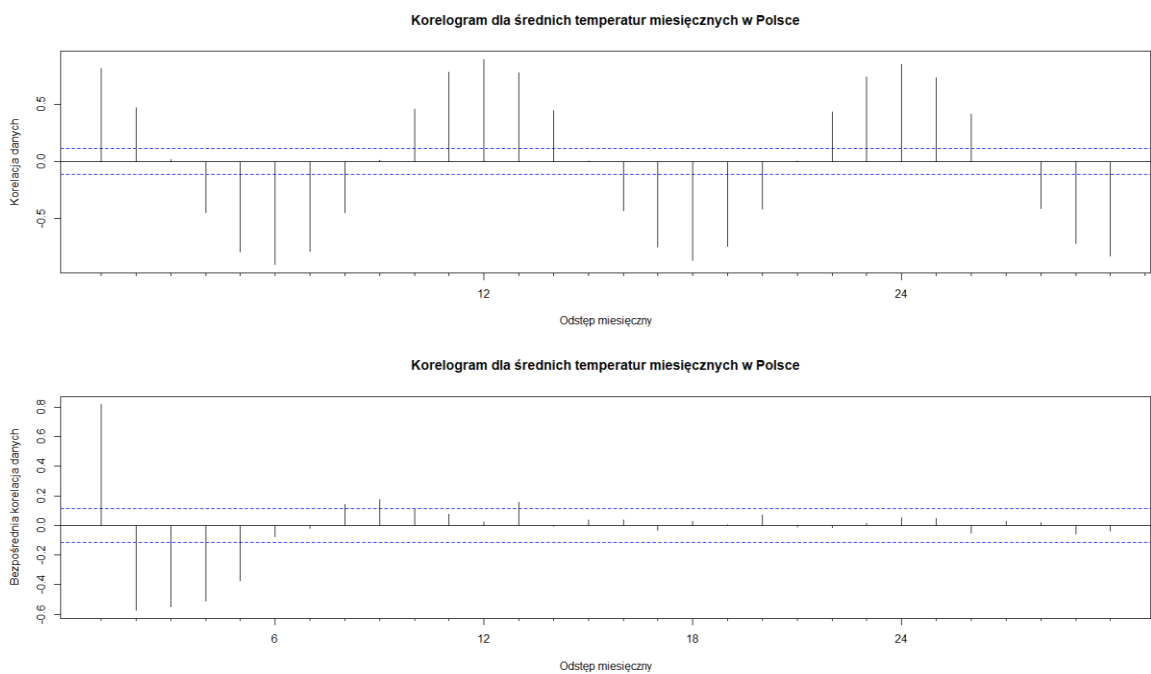
Dla szeregu miesięcznego widzimy największą korelację (zależność) danych dla opóźnienia z krokiem dwunastym, co pokazuje wyraźnie sezonowość roczną. Najśłabsza natomiast dla opóźnienia z krokiem trzecim/dziwartym, gdzie punkty układają się na kształt koła, co pokazuje działanie poszczególnych pór roku (zimniejszych i cieplejszych). Po przeciwnych stronach widocznej linii na wykresie z opóźnieniem szóstym powinny znaleźć się większości temperatur z przeciwnych pór roku.



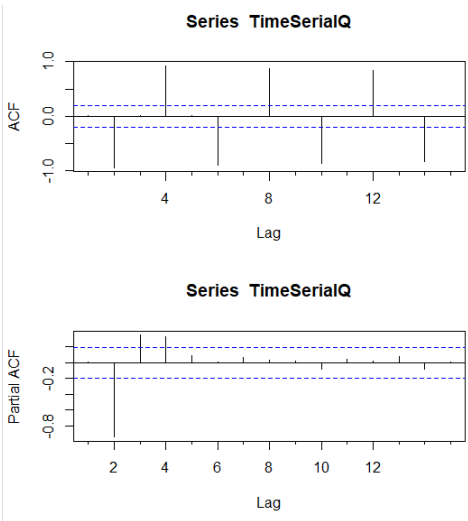
Analogicznie dla szeregu kwartałowego – największa korelacja występuje dla kroku czwartego (sezonowość 4-kwartałowa), a wykresy: pierwszy i trzeci pokazują działanie pór roku, drugi natomiast przeciwne z nich.



8) Wykresy funkcji autokorelacji – Acf, cząstkowej autokorelacji – Pacf




Widoczna jest duża sezonowość poprzez łagodne, regularne zmiany na wykresie funkcji Acf , oraz dzięki dużej „szpilce” przy odstępie sezonowym – 1. Brak widocznego wyraźnie trendu comiesięcznego.




Widoczna sezonowość, jednak dla bardzo krótkich odstępów czasowych (2-kwartałowej)


**9) Wygładzenie danych poprzez użycie średniej ruchomej**



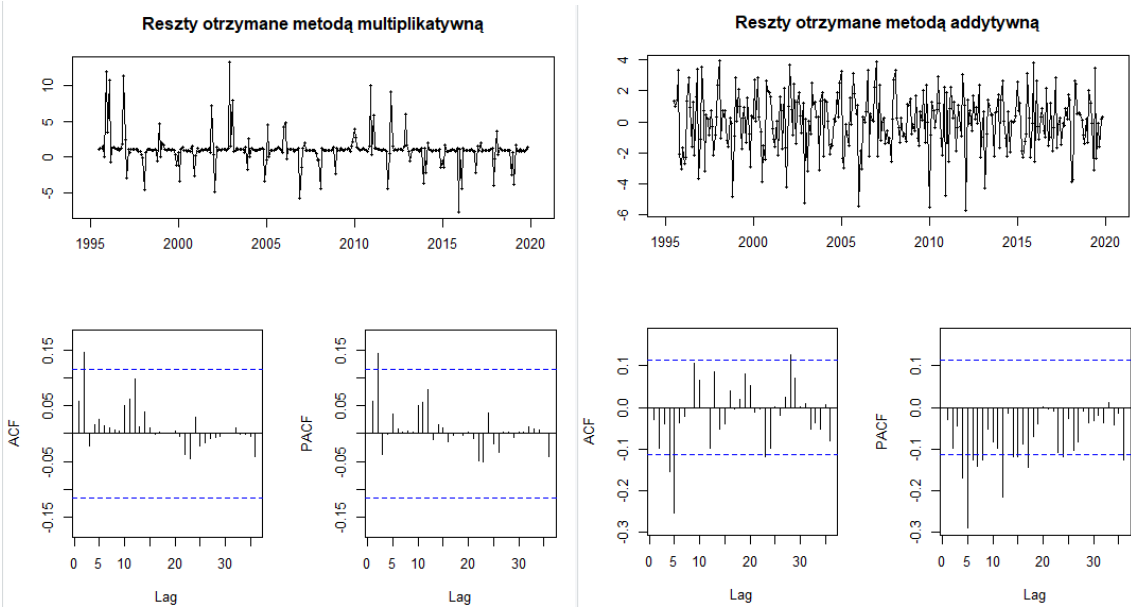
Przykładowe wykresy pokazują wygładzenie szeregu miesięcznego dla odstępu: dwu/sześć-miesięcznego, oraz szeregu dziennego dla odstępu 14/100 – dniowego oznaczonych kolejno według wielkości spłaszczenia kolorami czerwonym i zielonym.

**4. Dekompozycja przykładowych szeregów metodami: addytywną, multiplikatywną**





Metoda multiplikatywna w tym przypadku nie poprawiła bardzo rezultatu, ponieważ brak dużego trendu wzrostowego w danym szeregu. Porównajmy ich reszty i wykresy autokorelacji:




## 5. Dekompozycje na podstawie modelu regresji: trend liniowy/wielomianowy, sezonowość, transformacja Boxa-Coxa

```


timeserialM_T <- tslm(TimeserialM ~ trend)
TimeserialM_S <- tslm(TimeserialM ~ season)
TimeserialM_TS <- tslm(TimeserialM ~ trend + season)
timeserialM_TSB <- tslm((TimeserialM) ~ trend + season, lambda = 0.5) # Pierwiastkowa, ew. "auto"
# Trend wielomianowy
TimeserialM_WS<- tslm(TimeserialM ~ poly(trend,row=TRUE,degree=2)+season)
TimeserialM_WSB<- tslm(TimeserialM ~ poly(trend,row=TRUE,degree=2)+season, lambda=0.5)
summary(TimeserialM_TSB) # Informacje o przykładowym z wybranych modeli

# Porównamy metody
par(mfrow = c(2,1))
plot(TimeserialM, main="Rozkład temperatur miesięcznych w Polsce",
      xlab = "Rok", ylab="Odchyłka temperatury [C]")
lines(fitted(TimeserialM_T), col = "orange", lty = 2) # wizualizacja wykrytego trendu
lines(fitted(TimeserialM_S), col = "darkblue", lty = 2) # wizualizacja wykrytej sezonowości
lines(fitted(TimeserialM_TS), col = "green", lty = 2) # wizualizacja wykrytych: trendu, stacjonarności
lines(fitted(TimeserialM_TSB), col = "red", lty = 2) # wizualizacja wykrytych: jw., wariancji
plot(TimeserialM, main="Rozkład temperatur miesięcznych w Polsce",
      xlab = "Rok", ylab="Odchyłka temperatury [C]")
lines(fitted(TimeserialM_WS), col = "darkblue", lty = 2) # wizualizacja wykrytych: jw, trend kwadratowy
lines(fitted(TimeserialM_WSB), col = "red", lty = 2) # wizualizacja wykrytych: jw, trend kwadratowy

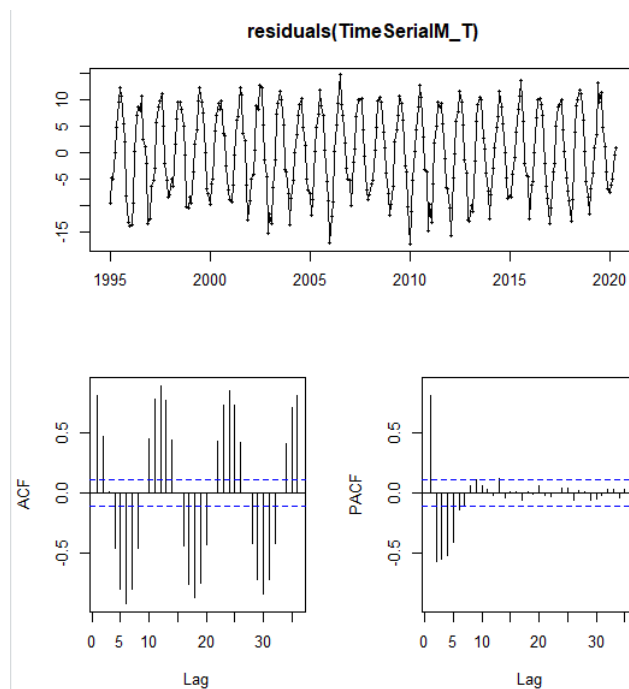
```




Porównamy reszty z różnych metod dekompozycji na podstawie modelu regresji. Po zastosowaniu dekompozycji metodą addytywną reszty wyglądają, jak na następnej stronie:




Po wyeliminowaniu trendu rezultat następujący:



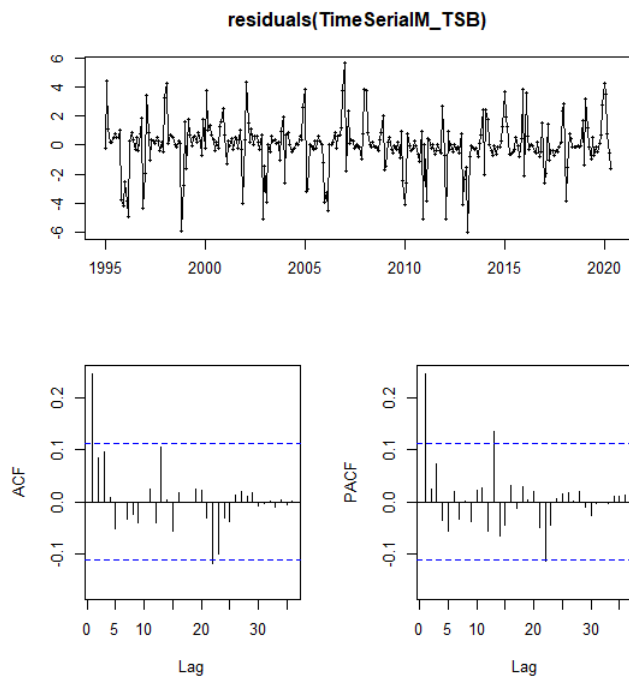
Następnie wyeliminowano sezonowość:



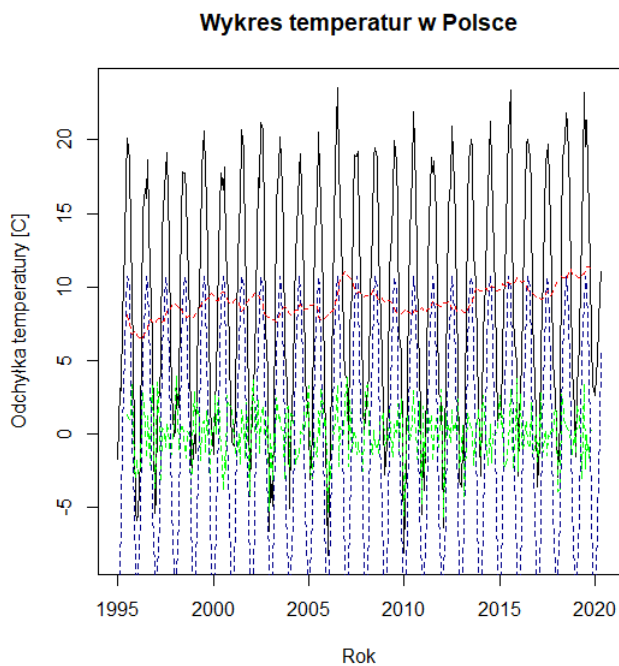
Przy jednoczesnym wyeliminowaniu trendu, sezonowości reszty wyglądają tak:



Przy użyciu dodatkowo transformacji Boxa-Coxa można ustabilizować wariancję, jak na następnej stronie:

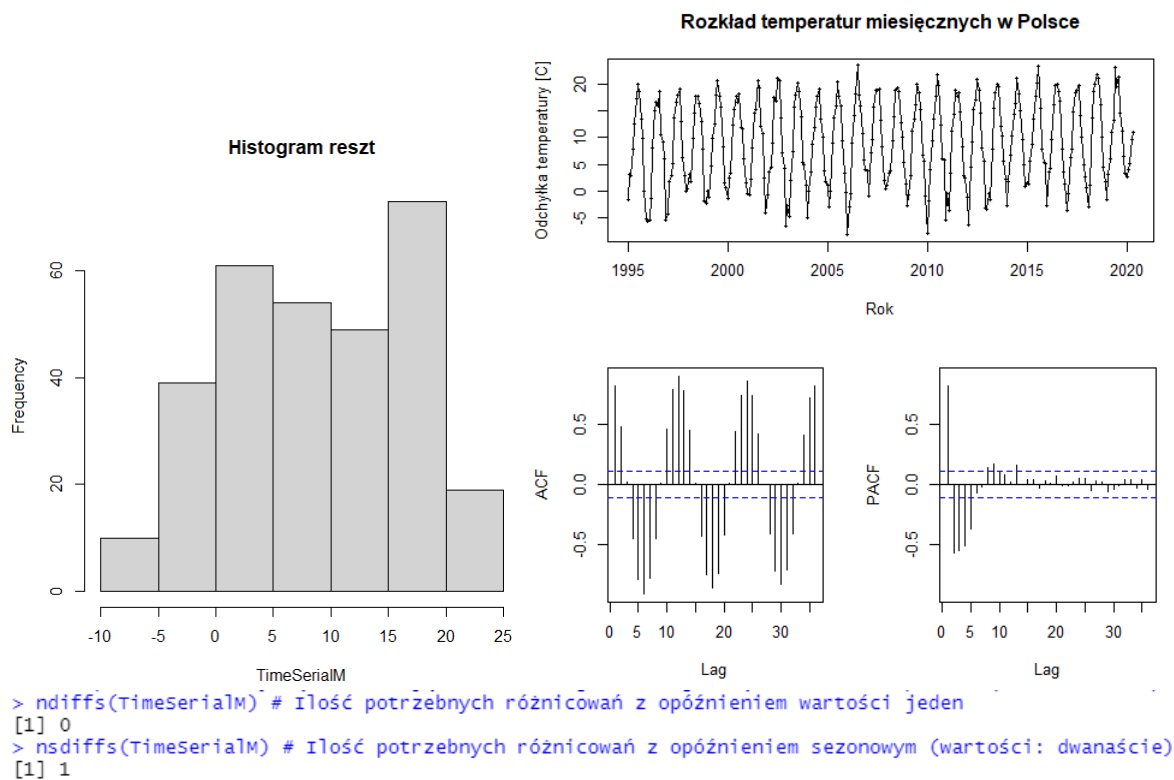


## 6. Eliminacja trendu i sezonowości z użyciem `decompose()`, wizualizacja rezultatu

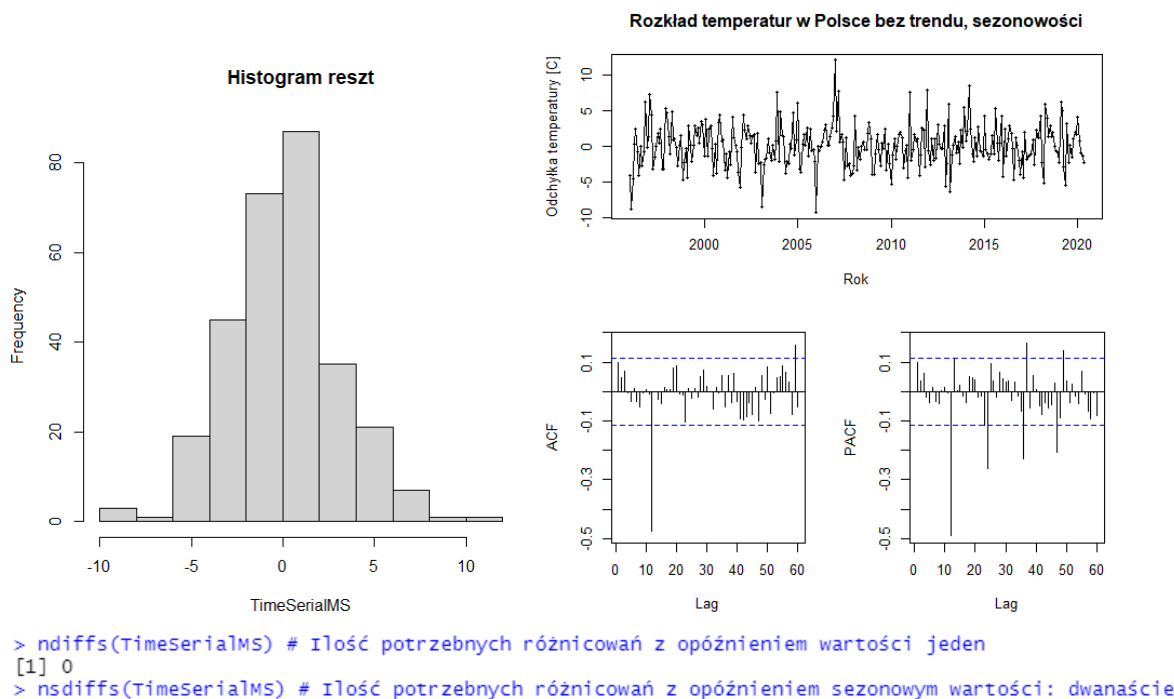


Kolorem ciemnoniebieskim oznaczono wykrytą sezonowość, czerwonym trend, a zielonym pozostałe reszty.

## 7. Uczynienie szeregu stacjonarnym – eliminacja trendu, sezonowości poprzez różnicowanie i stabilizacja wariancji poprzez transformację Boxa-Coxa



Otrzymany histogram i szereg po zróżnicowaniu z krokiem dwunastym:




Po przyglądnięciu się wykresom funkcji autokorelacji bezpośredniej i cząstkowej możemy założyć pewne modele z konkretnymi współczynnikami w celu identyfikacji szeregu. Wartości wykraczające poza przedział ufności na wykresie Acf to: 12, 59 ; dla wykresu Pacf



to: 12, 24, 36, 47, 49. Poprawnym byłoby założenie więc modeli np.: MA(12), MA(59), AR(12), AR(49).

8. Sprawdzenie stacjonarności otrzymanego szeregu



Widoczne są wyraźne duże odchyłki od przedziału ufności, nie możemy więc przyjąć danego szereg za stacjonarny. Wartość maksymalnej odchyłki wyznaczyliśmy ze wzoru:

$$x = \frac{1.96}{\sqrt{\text{dł.szeregu}}}$$

9. Wyznaczenie współczynników modelu autoregresji i porównanie dopasowania różnymi metodami estymacji

```
Call:
ar(x = TimeSeriesMS2, aic = FALSE, order.max = 12, method = c("yule-walker"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12
0.0909  0.0415  0.0628 -0.0362 -0.0488  0.0261 -0.0462 -0.0504  0.0334  0.0300  0.0420 -0.4881

Order selected 12  sigma^2 estimated as  6.9

Call:
ar(x = TimeSeriesMS2, aic = FALSE, order.max = 12, method = c("burg"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12
0.0903  0.0448  0.0663 -0.0363 -0.0518  0.0236 -0.0474 -0.0509  0.0370  0.0337  0.0436 -0.5140

Order selected 12  sigma^2 estimated as  6.364

Call:
ar(x = TimeSeriesMS2, aic = FALSE, order.max = 12, method = c("ols"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12
0.0657  0.0555  0.0751 -0.0288 -0.0699  0.0036 -0.0604 -0.0428  0.0596  0.0402  0.0423 -0.5009

Intercept: 0.0474 (0.1482)

Order selected 12  sigma^2 estimated as  6.147
```

```
Call:
ar(x = TimeSeriesMS2, aic = FALSE, order.max = 12, method = c("mle"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12
0.0927 0.0511 0.0767 -0.0369 -0.0618 0.0137 -0.0559 -0.0423 0.0457 0.0377 0.0300 -0.5176

Order selected 12  sigma^2 estimated as 6.356
Call:
ar(x = TimeSeriesMS2, aic = FALSE, order.max = 12, method = c("yw"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12
0.0909 0.0415 0.0628 -0.0362 -0.0488 0.0261 -0.0462 -0.0504 0.0334 0.0300 0.0420 -0.4881

Order selected 12  sigma^2 estimated as 6.9
```

Automatyczny dobór rzędu dzięki kryterium „aic”:

```
Call:
ar(x = TimeSeriesMS2, aic = TRUE, order.max = 100, method = c("yule-walker"))

Coefficients:
      1      2      3      4      5      6      7      8      9     10     11     12     13     14
0.1559 0.0571 0.0539 -0.0206 -0.0349 0.0378 -0.0204 -0.0158 -0.0005 0.0682 -0.0232 -0.7530 0.2404 0.0608
15      16      17      18      19      20      21      22      23      24      25      26      27      28
0.0105 0.0244 -0.0157 0.0398 0.0267 0.0122 0.0004 0.0698 -0.1534 -0.5074 0.2659 0.0255 -0.0007 0.0621
29      30      31      32      33      34      35      36      37      38      39      40      41      42
0.0343 -0.0121 0.0034 -0.0343 0.0182 0.0584 -0.1703 -0.3350 0.2711 -0.0479 0.0433 0.0100 -0.0186 -0.0625
43      44      45      46      47      48      49
-0.0392 -0.0309 -0.0326 0.0550 -0.1976 -0.1079 0.1384

Order selected 49  sigma^2 estimated as 5.86
```

## 10. Wyznaczenie współczynników modelu ruchomej średniej z użyciem funkcji Arima()

ARIMA(0,0,12) with non-zero mean

```
Coefficients:
      ma1      ma2      ma3      ma4      ma5      ma6      ma7      ma8      ma9      ma10      ma11      ma12      mean
0.0722 0.0040 0.0642 0.0716 0.0005 0.0371 0.0552 0.0267 0.0520 0.0068 -0.0189 -0.9211 -0.0002
s.e. 0.0505 0.0495 0.0528 0.0495 0.0536 0.0522 0.0546 0.0521 0.0537 0.0524 0.0538 0.0503 0.0602

sigma^2 estimated as 4.563: log likelihood=-645.97
AIC=1319.94 AICC=1321.45 BIC=1371.46

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.01116456 2.088196 1.608391 -142.0788 454.1568 0.4036136 0.07980073
ARIMA(0,0,12)(0,1,0)[12]
```

```
Coefficients:
      ma1      ma2      ma3      ma4      ma5      ma6      ma7      ma8      ma9      ma10      ma11      ma12
0.065 0.0162 0.0062 -0.0019 -0.0092 0.0000 0.0091 0.0020 -0.0062 -0.0162 -0.0650 -0.9999
s.e. 0.043 0.0425 0.0442 0.0426 0.0429 0.0323 0.0429 0.0426 0.0442 0.0425 0.0431 0.0321

sigma^2 estimated as 9.504: log likelihood=-728.11
AIC=1482.23 AICC=1483.59 BIC=1529.53

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.127625 2.953832 2.203956 169.0288 217.4336 0.5530662 0.02988073
```

## 11. Porównanie modelu ruchomej średniej z modelem autoregresji, analiza dobroci dopasowania

ARIMA(12,0,0) with non-zero mean

Coefficients:

	ar1	ar2	ar3	ar4	ar5	ar6	ar7	ar8	ar9	ar10	ar11	ar12	mean
	0.0927	0.0511	0.0767	-0.0369	-0.0618	0.0137	-0.0559	-0.0422	0.0457	0.0377	0.0300	-0.5175	0.0136
s.e.	0.0498	0.0508	0.0508	0.0509	0.0509	0.0516	0.0510	0.0509	0.0510	0.0508	0.0511	0.0507	0.1095

sigma^2 estimated as 6.651: log likelihood=-688.6  
AIC=1405.19 AICc=1406.71 BIC=1456.72

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	-0.0196012	2.521146	1.956804	-130.573	456.1641	0.491045	0.05388818

ARIMA(12,0,0)(0,1,0)[12]

Coefficients:

	ar1	ar2	ar3	ar4	ar5	ar6	ar7	ar8	ar9	ar10	ar11	ar12
	0.0669	0.0288	0.053	-0.0284	-0.0394	-0.0002	-0.0527	-0.0552	0.0333	0.0373	0.0450	-0.6857
s.e.	0.0431	0.0438	0.044	0.0443	0.0440	0.0454	0.0440	0.0442	0.0443	0.0441	0.0444	0.0435

sigma^2 estimated as 14.59: log likelihood=-773.01  
AIC=1572.02 AICc=1573.38 BIC=1619.32

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	0.09650005	3.65962	2.675325	78.26202	385.4588	0.6713526	0.06324382

ARIMA(24,0,0) with non-zero mean

Coefficients:

	ar1	ar2	ar3	ar4	ar5	ar6	ar7	ar8	ar9	ar10	ar11	ar12	ar13	ar14
	0.1055	0.0568	0.0957	-0.0271	-0.0735	0.0416	-0.0526	-0.0133	0.0493	0.0395	-0.0103	-0.6756	0.1074	0.0331
s.e.	0.0559	0.0565	0.0565	0.0570	0.0569	0.0579	0.0569	0.0570	0.0567	0.0567	0.0569	0.0571	0.0575	0.0582
	ar15	ar16	ar17	ar18	ar19	ar20	ar21	ar22	ar23	ar24	mean			
	0.0388	-0.0271	-0.0653	0.0366	0.0141	0.0534	0.0319	0.0135	-0.1035	-0.3038	0.0078			
s.e.	0.0584	0.0592	0.0592	0.0596	0.0592	0.0590	0.0589	0.0587	0.0583	0.0585	0.0869			

sigma^2 estimated as 6.062: log likelihood=-670.16  
AIC=1392.32 AICc=1397.6 BIC=1488.01

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	-0.02159083	2.354773	1.828477	-82.50449	423.5169	0.4588426	0.02828464

## 12. Wyznaczenie optymalnych modeli z wykorzystaniem funkcji auto.arima(), oraz ich porównanie na podstawie kryteriów dopasowania, wybór najlepszego

ARIMA(1,0,1)(2,0,2)[12] with zero mean

Coefficients:

	ar1	ma1	sar1	sar2	sma1	sma2
	0.6863	-0.5367	0.5299	-0.0758	-1.528	0.6059
s.e.	0.1844	0.2134	0.1899	0.0794	0.180	0.1704

sigma^2 estimated as 4.485: log likelihood=-643.29  
AIC=1300.57 AICc=1300.97 BIC=1326.34  
ARIMA(1,0,0)(2,0,2)[12] with zero mean

Coefficients:

	ar1	sar1	sar2	sma1	sma2
	0.1665	0.5372	-0.0623	-1.5269	0.5956
s.e.	0.0616	0.3636	0.0858	0.3560	0.3296

sigma^2 estimated as 4.522: log likelihood=-645.04  
AIC=1302.07 AICc=1302.37 BIC=1324.15  
ARIMA(1,0,0)(2,0,2)[12] with zero mean

Coefficients:

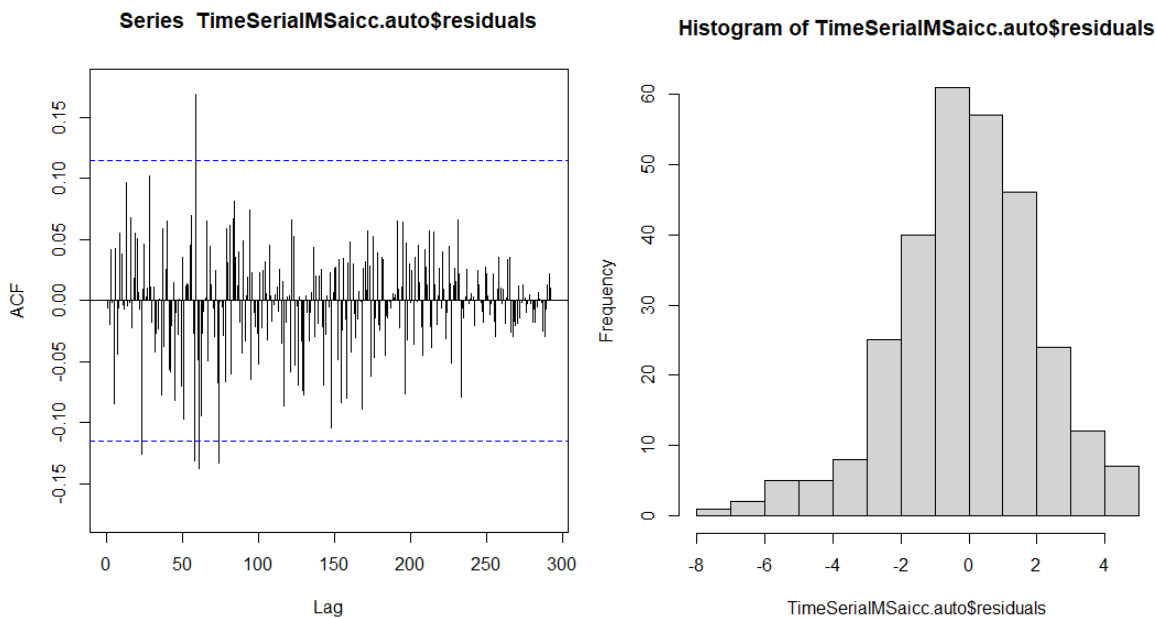
	ar1	sar1	sar2	sma1	sma2
	0.1665	0.5372	-0.0623	-1.5269	0.5956
s.e.	0.0616	0.3636	0.0858	0.3560	0.3296

sigma^2 estimated as 4.522: log likelihood=-645.04  
AIC=1302.07 AICc=1302.37 BIC=1324.15

Najlepszym modelem jest na podstawie kryteriów dobroci dopasowania: aic, aicc, bic (głównie dwóch ostatnich) - ARIMA(1,0,0)(2,0,2)[12], ponieważ kryteria tego modelu są

najbliższe zero. Współczynniki każdego z trzech powyższych modeli są bardzo zbliżone, a pierwszych dwóch nawet identyczne. W każdym z przypadków wyznaczono ten sam model.

### 13. Test stacjonarności automatycznie dobranego modelu

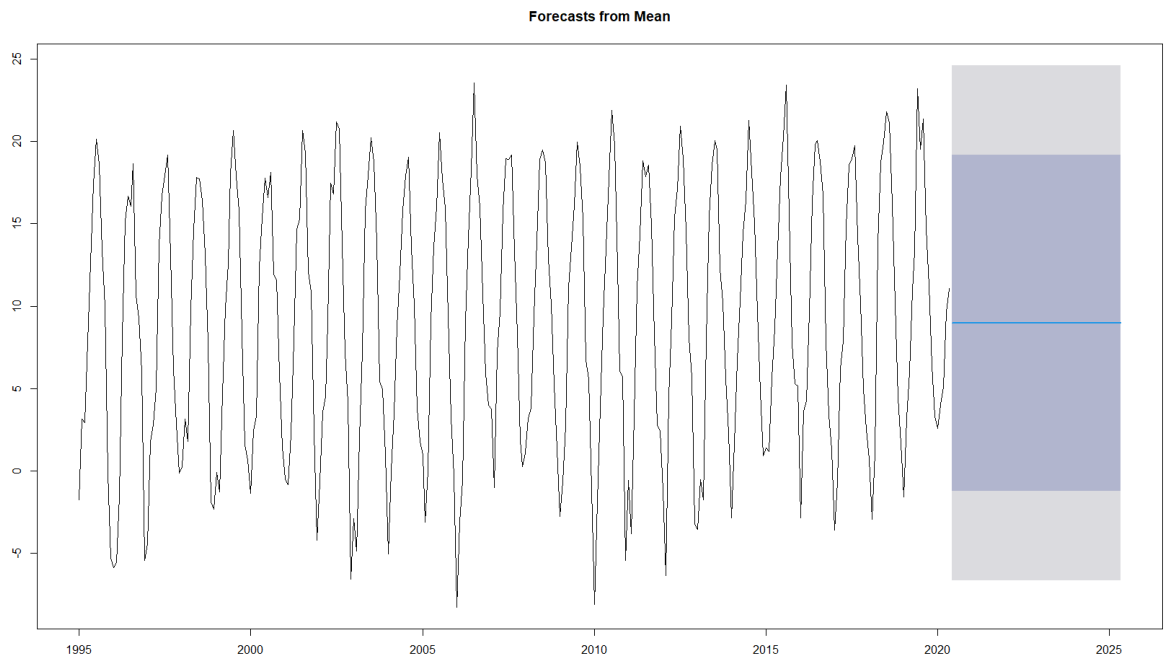


Jest to szereg stacjonarny, ponieważ żadna z wartości nie wystaje znacząco poza przedział ufności (na podstawie wcześniej wspomnianego wzoru). Histogram przedstawia rozkład normalny. Potwierdzone to jest także testem Shapiro-Wilka, gdzie wartość zmiennej p nie przekracza: 0,05.

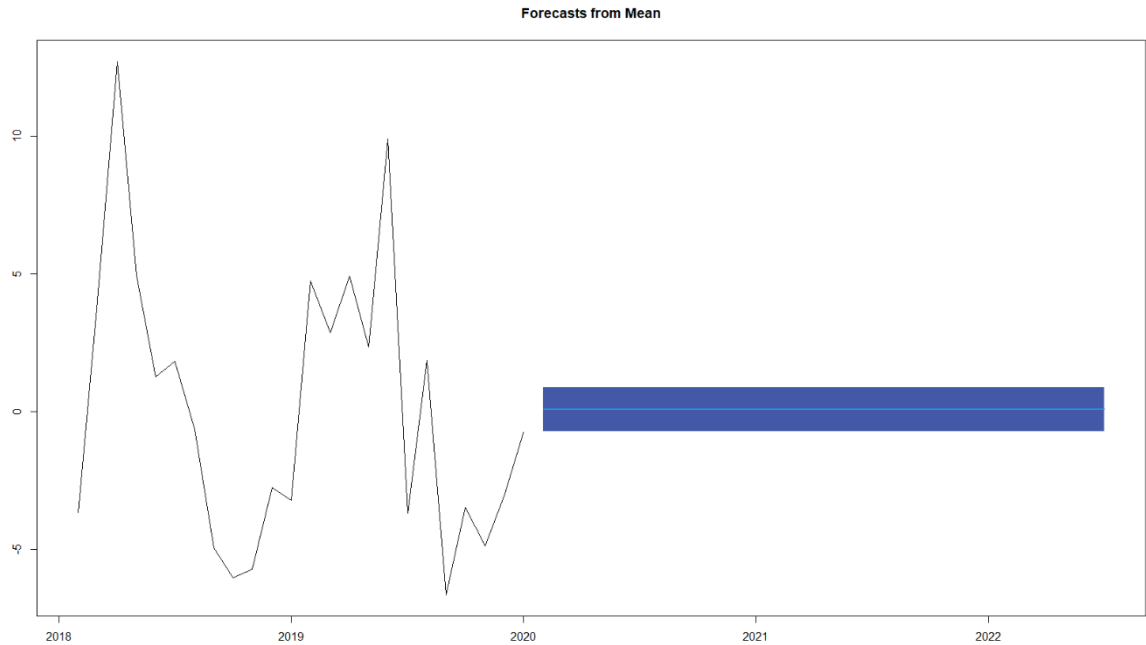
```
shapiro-wilk normality test
data: TimeSeriesMSaicc.auto$residuals
w = 0.98575, p-value = 0.005308
```

# 14.Prognozowanie z wykorzystaniem metod naiwnych

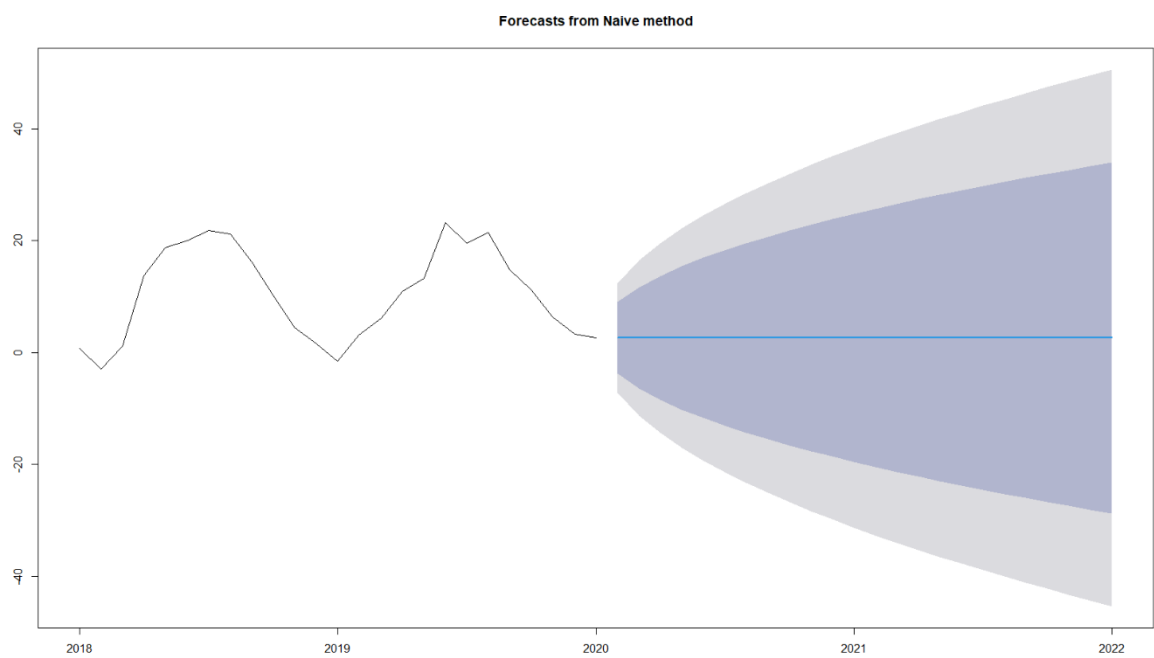
## 10) Prognoza oparta na średniej




## 11) Prognoza po wyeliminowaniu sezonowości




12) Prognozowanie naiwne z użyciem funkcji naive()



13) Prognozowanie z użyciem funkcji snaive()



## 14) Prognozowanie naiwne z dryfem



Najlepszą metodą w celu prognozy temperatur jest zastosowanie tutaj funkcji `snaive()` z powodu bardzo wyraźnej sezonowości szeregu.

# Rozdział drugi – szereg z wyraźnym trendem

## 1. Wprowadzenie do analizowanych danych

Dane z szeregu z trendem dotyczą liczby szczepień na COVID-19 w państwach danego roku. Analizowane będą dane wyłącznie dla Polski od marca danego roku. Zostały one pobrane ze strony:

<https://www.kaggle.com/gpreda/covid-world-vaccination-progress>

### 1) Informacje o ramce danych:

```
'data.frame': 23468 obs. of 15 variables:
 $ country      : chr "Afghanistan" "Afghanistan" "Afghanistan" "Afghanistan" ...
 $ iso_code     : chr "AFG" "AFG" "AFG" "AFG" ...
 $ date         : chr "2021-02-22" "2021-02-23" "2021-02-24" "2021-02-25" ...
 $ total_vaccinations : num 0 NA NA NA NA NA 8200 NA NA ...
 $ people_vaccinated : num 0 NA NA NA NA NA 8200 NA NA ...
 $ people_fully_vaccinated : num NA NA NA NA NA NA NA NA ...
 $ daily_vaccinations_raw : num NA NA NA NA NA NA NA NA ...
 $ daily_vaccinations : num NA 1367 1367 1367 1367 ...
 $ total_vaccinations_per_hundred : num 0 NA NA NA NA NA 0.02 NA NA ...
 $ people_vaccinated_per_hundred : num 0 NA NA NA NA NA 0.02 NA NA ...
 $ people_fully_vaccinated_per_hundred : num NA NA NA NA NA NA NA NA ...
 $ daily_vaccinations_per_million : num NA 35 35 35 35 35 41 46 52 ...
 $ vaccines     : chr "Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing" "Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing" "Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing" ...
 $ source_name  : chr "World Health organization" "World Health organization" "World Health organization" ...
 $ source_website : chr "https://covid19.who.int/" "https://covid19.who.int/" "https://covid19.who.int/" ...
```

### 2) Przykładowe rekordy danych:


	country	iso_code	date	total_vaccinations	people_vaccinated	people_fully_vaccinated	daily_vaccinations_raw	daily_vaccinations
1	Afghanistan	AFG	2021-02-22	0	0	NA	NA	NA
2	Afghanistan	AFG	2021-02-23	NA	NA	NA	NA	1367
3	Afghanistan	AFG	2021-02-24	NA	NA	NA	NA	1367
4	Afghanistan	AFG	2021-02-25	NA	NA	NA	NA	1367
5	Afghanistan	AFG	2021-02-26	NA	NA	NA	NA	1367
6	Afghanistan	AFG	2021-02-27	NA	NA	NA	NA	1367
	total_vaccinations_per_hundred	people_vaccinated_per_hundred	people_fully_vaccinated_per_hundred	daily_vaccinations_per_million				
1	0	0	NA	NA				
2	NA	NA	NA	35				
3	NA	NA	NA	35				
4	NA	NA	NA	35				
5	NA	NA	NA	35				
6	NA	NA	NA	35				
	vaccines	source_name	source_website					
1	Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing	World Health organization	https://covid19.who.int/					
2	Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing	World Health organization	https://covid19.who.int/					
3	Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing	World Health organization	https://covid19.who.int/					
4	Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing	World Health organization	https://covid19.who.int/					
5	Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing	World Health organization	https://covid19.who.int/					
6	Oxford/Astrazeneca, Pfizer/BionTech, Sinopharm/Beijing	World Health organization	https://covid19.who.int/					

## 2. Utworzenie szeregów czasowych z średnimi: dziennymi, miesięcznymi, kwartalowymi (Po odpowiednim „wycięciu” potrzebnych danych, interpolacji wartości brakujących)

wybór kraju dla analizy danych (np. "Poland", "Palestine")


```
> sort(unique(my_data$country))
[1] "Afghanistan"
[5] "Angola"
[9] "Armenia"
[13] "Azerbaijan"
[17] "Barbados"
[21] "Benin"
[25] "Bonaire Sint Eustatius and Saba"
[29] "British Virgin Islands"
[33] "Cambodia"
[37] "Cayman Islands"
[41] "Colombia"
[45] "Costa Rica"
[49] "Curacao"
[53] "Denmark"
[57] "Ecuador"
[61] "Equatorial Guinea"
"Albania"
"Anguilla"
"Aruba"
"Bahamas"
"Belarus"
"Bermuda"
"Bosnia and Herzegovina"
"Brunei"
"Cameroon"
"Central African Republic"
"Comoros"
"Cote d'Ivoire"
"Cyprus"
"Djibouti"
"Egypt"
"Estonia"
"Algeria"
"Antigua and Barbuda"
"Australia"
"Bahrain"
"Belgium"
"Bhutan"
"Botswana"
"Bulgaria"
"Canada"
"Chile"
"Congo"
"Croatia"
"Czechia"
"Dominica"
"El Salvador"
"Eswatini"
"Andorra"
"Argentina"
"Austria"
"Bangladesh"
"Belize"
"Bolivia"
"Brazil"
"Burkina Faso"
"Cape Verde"
"China"
"Cook Islands"
"Cuba"
"Democratic Republic of Congo"
"Dominican Republic"
"England"
"Ethiopia"
```






### 3. Reprezentacja szeregu czasowego na różnego rodzaju wykresach


#### 1) Wykres z użyciem xyplot()



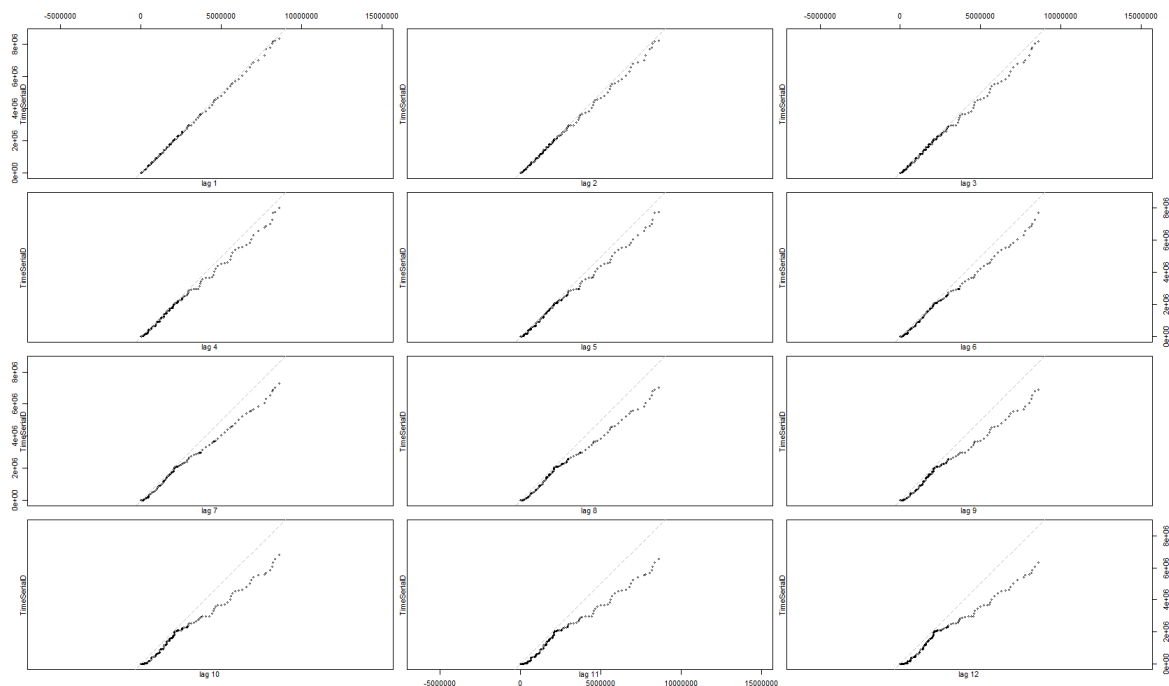
2) Wykres panelowy



3) Wykres pudełkowy




4) Wykres rozrzutu wartości opóźnionych




Dla danego szeregu widzimy największą korelację (zależność) danych dla opóźnienia z krokiem pierwszym, co pokazuje wyraźny trend wzrostowy. Z każdym kolejnym krokiem korelacja danych maleje, co oznacza gorzej dobrany współczynnik opóźnienia.

5) Wykresy funkcji autokorelacji – Acf, częściowej autokorelacji – Pacf




Widoczna jest wyraźny trend wzrostowy z opóźnieniem – jeden poprzez łagodne, regularne zmiany na wykresie funkcji Acf , oraz dzięki dużej „szpilce” przy odstępie sezonowym. Brak trendów z innymi opóźnieniami.

6) Wygladzenie danych poprzez uzycie sredniej ruchomej



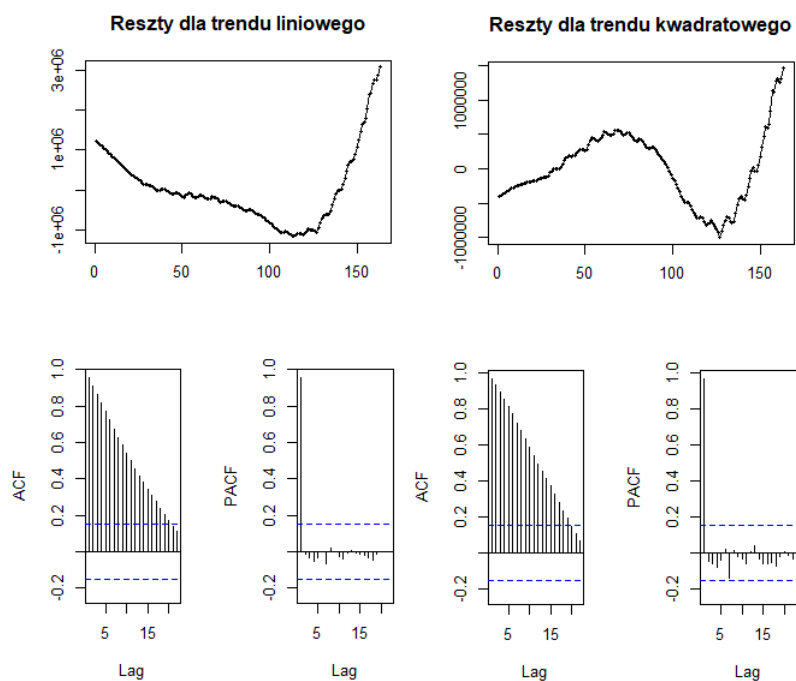
Wykres pokazuje wygladzenie szeregu dziennego dla odstępu: trzy/czternasto-dniowego, oznaczonych kolejno według wielkości spłaszczenia kolorami czerwonym i zielonym.

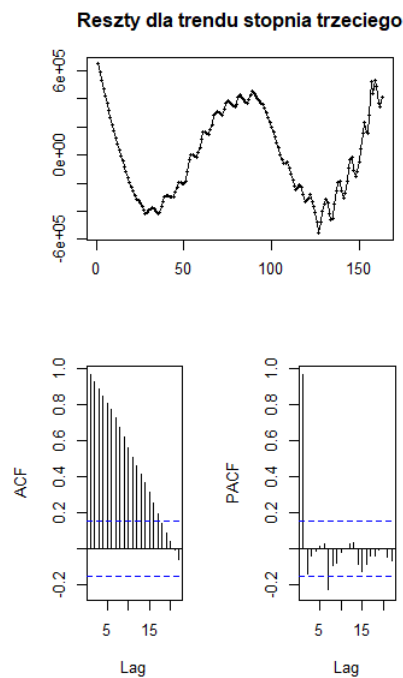
#### 4. Dekompozycje na podstawie modelu regresji: trend liniowy/wielomianowy, transformacje Boxa-Coxa




Wykres pierwszy pokazuje wykryte trendy kolejnych stopni: liniowy, kwadratowy, oraz stopnia trzeciego, oznaczonych kolejno kolorami: zielonym, czerwonym, niebieskim. Drugi z wykresów przedstawia transformacje Boxa-Coxa: pierwiastkową, logarytmiczną i z automatycznie dobranym współczynnikiem lambda, oznaczonych kolejno kolorami: zielonym, czerwonym, niebieskim. Na ich podstawie możemy stwierdzić, że koniecznym założeniem jest tutaj trend wielomianowy, najprawdopodobniej stopnia trzeciego.


Porównamy reszty z różnych metod dekompozycji na podstawie modelu regresji:






## 5. Uczynienie szeregu stacjonarnym – eliminacja trendu, sezonowości poprzez różnicowanie i stabilizacja wariancji poprzez transformację Boxa-Coxa

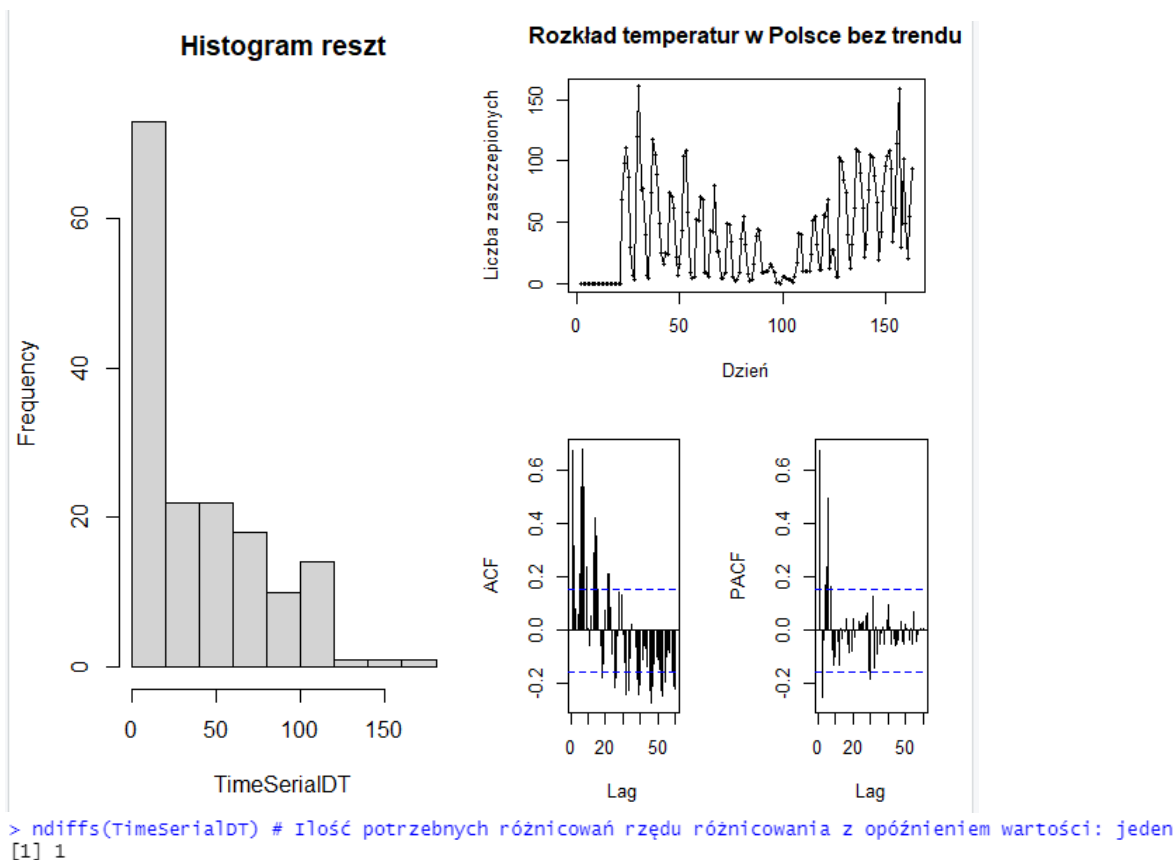




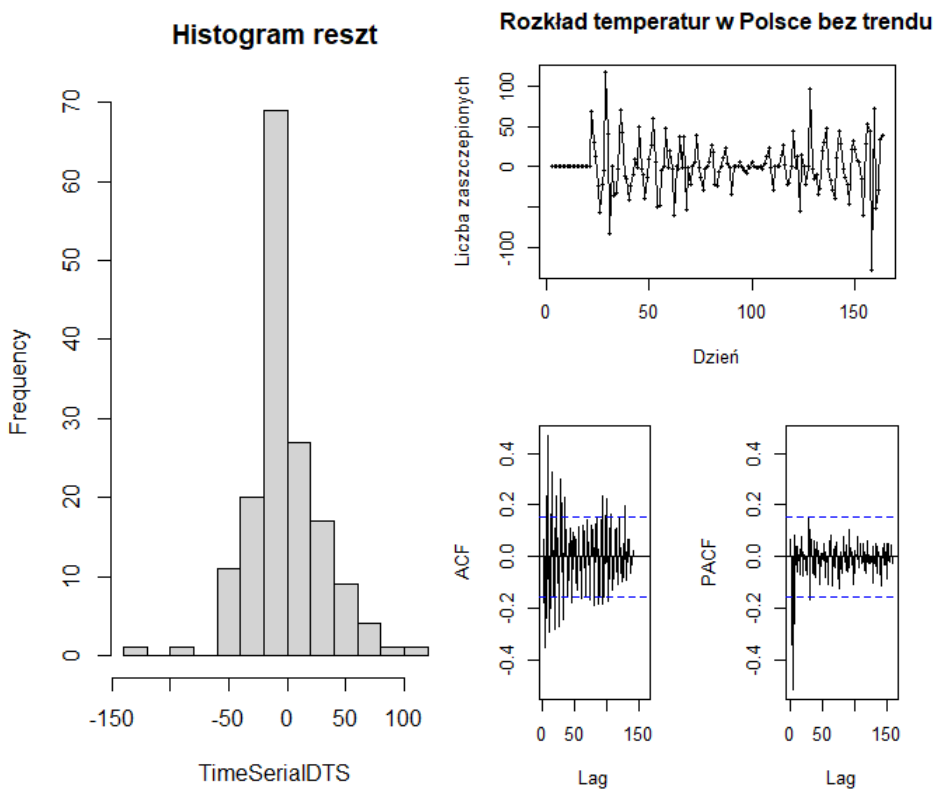
Po zastosowaniu transformacji Boxa-Coxa z automatycznie dobranym współczynnikiem lambda szereg i jego histogram, oraz wykresu autokorelacji wyglądają następująco:



Po pierwszym zróżnicowaniu danych z opóźnieniem pierwszym wygląda to, jak na następnej stronie:




Po drugim zróżnicowaniu danych z opóźnieniem pierwszym wygląda to następująco:




Widoczna jednak dalej jest pewna sezonowość reszt. W celu doboru rzędu różnicowania sprawdzimy wykresy rozrzutu.






Po zróżnicowaniu z opóźnieniem – siedem wygląda to następująco:



Po przyglądnięciu się wykresom funkcji autokorelacji bezpośredniej i cząstkowej możemy założyć pewne modele z konkretnymi współczynnikami w celu identyfikacji szeregu. Wartości wykraczające poza przedział ufności na wykresie Acf to: 1, 7, 8, 21, 23, 30, 31; dla wykresu Pacf to: 1, 3, 7, minimalnie 14, 21, 22. Poprawnym byłoby założenie więc modeli np.: MA(1), MA(31), AR(1), AR(7).

## 6. Sprawdzenie stacjonarności otrzymanego szeregu



Brak widocznych wyraźnych odchyłek od przedziału ufności, możemy więc przyjąć dany szereg za stacjonarny. Wartość maksymalnej odchyłki wyznaczyliśmy ze wzoru:  $x =$

$$\frac{1.96}{\sqrt{\text{dł.szeregu}}}$$

## 7. Wyznaczenie współczynników modelu autoregresji i porównanie dopasowania różnymi metodami estymacji

```
Call:
ar(x = TimeSerialDNM, aic = FALSE, order.max = 1, method = c("yule-walker"))
```

Coefficients:

```
1
-0.3017
```

Order selected 1 sigma^2 estimated as 771.6

```
Call:
ar(x = TimeSerialDNM, aic = FALSE, order.max = 1, method = c("burg"))
```

Coefficients:

```
1
-0.3019
```

Order selected 1 sigma^2 estimated as 761.5

```
Call:
ar(x = TimeSerialDNM, aic = FALSE, order.max = 1, method = c("ols"))
```

Coefficients:

```
1
-0.3021
```

Intercept: 0.02444 (2.238)

Order selected 1 sigma^2 estimated as 766.5

```
Call:
ar(x = TimeSerialDNM, aic = FALSE, order.max = 1, method = c("mle"))
```

Coefficients:

```
1
-0.3002
```

Order selected 1 sigma^2 estimated as 761.5

```
Call:
ar(x = TimeSerialDNM, aic = FALSE, order.max = 1, method = c("yw"))
```

Coefficients:

```
1
-0.3017
```

Order selected 1 sigma^2 estimated as 771.6

Automatyczny dobór rzędu dzięki kryterium „aic”:

```
Call:
ar(x = TimeSeriesDNM, aic = TRUE, order.max = 100, method = c("yule-walker"))

Coefficients:
      1      2      3      4      5      6      7
-0.4339 -0.3527 -0.3874 -0.2801 -0.2079 -0.1070 -0.2937

order selected 7  sigma^2 estimated as 646.1
```

## 8. Wyznaczenie współczynników modelu ruchomej średniej z użyciem funkcji Arima()

```
ARIMA(0,0,1) with non-zero mean

Coefficients:
      ma1      mean
-0.6073  0.0219
s.e.    0.1164  0.8493

sigma^2 estimated as 715:  log likelihood=-723.81
AIC=1453.62  AICC=1453.78  BIC=1462.73

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.004000951 26.56592 17.68786 24.05806 311.4821 0.5644599 0.1493788

ARIMA(0,0,7) with non-zero mean

Coefficients:
      ma1      ma2      ma3      ma4      ma5      ma6      ma7      mean
-0.2768 -0.3701 -0.3430 -0.0049  0.1319  0.4055 -0.5425  0.1010
s.e.    0.0744  0.0808  0.0793  0.0722  0.0832  0.0857  0.0809  0.1115

sigma^2 estimated as 569.6:  log likelihood=-706.35
AIC=1430.69  AICC=1431.94  BIC=1458.02

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.2527391 23.23713 15.51878 137.842 370.8928 0.4952398 -0.1249344
```

## 9. Porównanie modelu ruchomej średniej z modelem autoregresji, analiza dobroci dopasowania

```
ARIMA(1,0,0) with non-zero mean

Coefficients:
      ar1      mean
-0.3001  0.0190
s.e.    0.0766  1.7129

sigma^2 estimated as 771.5:  log likelihood=-729.48
AIC=1464.97  AICC=1465.13  BIC=1474.08

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.000248016 27.59571 18.05437 34.48005 240.9512 0.5761562 -0.05071994

ARIMA(7,0,0) with non-zero mean

Coefficients:
      ar1      ar2      ar3      ar4      ar5      ar6      ar7      mean
-0.4237 -0.3549 -0.3765 -0.2759 -0.2221 -0.0877 -0.3400  0.0341
s.e.    0.0760  0.0829  0.0854  0.0886  0.0857  0.0870  0.0811  0.6502

sigma^2 estimated as 631.1:  log likelihood=-711.56
AIC=1441.12  AICC=1442.37  BIC=1468.46

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.003049892 24.46013 15.93834 79.35744 203.1509 0.5086289 -0.003157649
```

## 10. Wyznaczenie optymalnych modeli z wykorzystaniem funkcji `auto.arima()`, oraz ich porównanie na podstawie kryteriów dopasowania, wybór najlepszego

ARIMA(1,0,1) with zero mean

Coefficients:

	ar1	ma1
	0.4416	-0.9686
s.e.	0.0813	0.0304

sigma^2 estimated as 629.4: log likelihood=-714.7  
AIC=1435.41 AICc=1435.57 BIC=1444.52

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	1.21456	24.92532	16.50394	149.1697	213.2714	0.5266785	-0.02032933

ARIMA(1,0,1) with zero mean

Coefficients:

	ar1	ma1
	0.4416	-0.9686
s.e.	0.0813	0.0304

sigma^2 estimated as 629.4: log likelihood=-714.7  
AIC=1435.41 AICc=1435.57 BIC=1444.52

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	1.21456	24.92532	16.50394	149.1697	213.2714	0.5266785	-0.02032933

ARIMA(1,0,1) with zero mean

Coefficients:

	ar1	ma1
	0.4416	-0.9686
s.e.	0.0813	0.0304

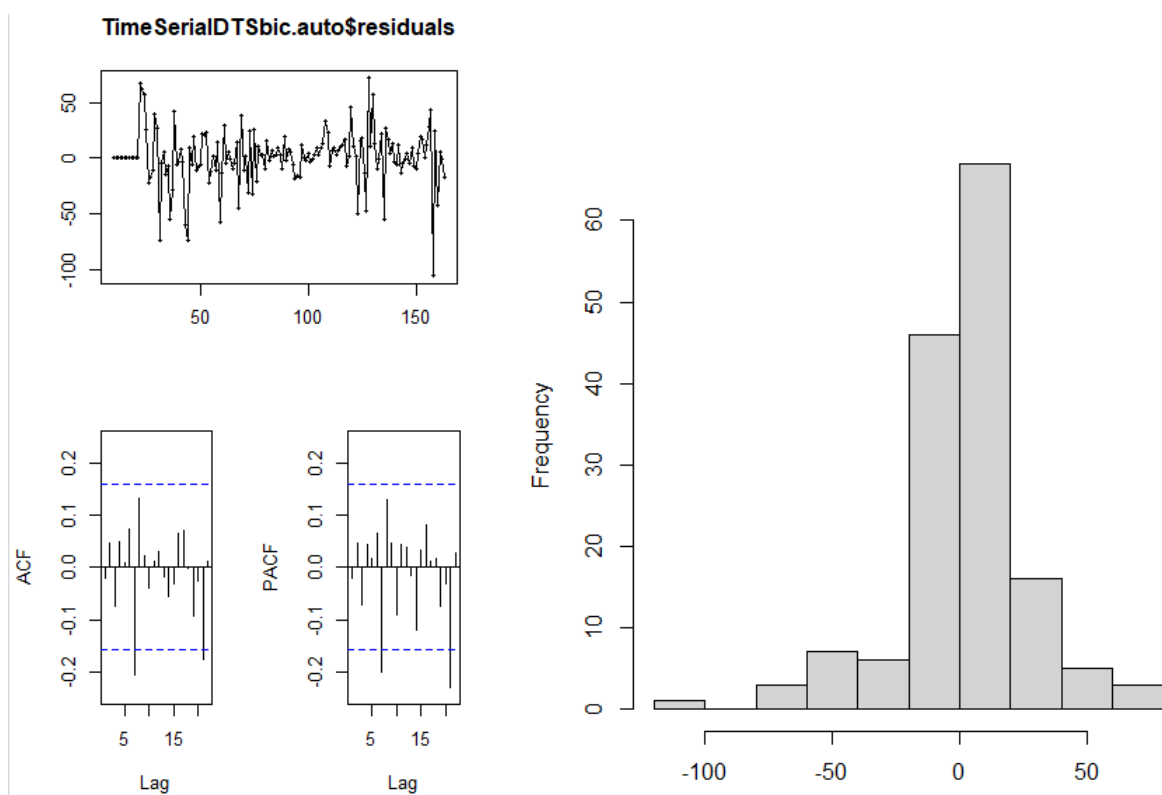
sigma^2 estimated as 629.4: log likelihood=-714.7  
AIC=1435.41 AICc=1435.57 BIC=1444.52

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	1.21456	24.92532	16.50394	149.1697	213.2714	0.5266785	-0.02032933

Najlepszym modelem jest więc - ARIMA(1,0,1) wyznaczona identycznie (z identycznymi współczynnikami) przez każde z kryteriów dobroci dopasowania: aic, aicc, bic.

## 11. Test stacjonarności automatycznie dobranego modelu




Jest to szereg stacjonarny, ponieważ żadna z wartości nie wystaje znacząco poza przedział ufności (na podstawie wcześniej wspomnianego wzoru). Histogram jest bardzo zbliżony do rozkładu normalnego. Test Shapiro-Wilka potwierdza, że nim jest, ponieważ wartość zmiennej  $p$  nie przekracza: 0,05.

Shapiro-wilk normality test


```
data: TimeSeriesMSaicc.auto$residuals  
w = 0.98575, p-value = 0.005308
```

## 12. Prognozowanie z wykorzystaniem metod naiwnych


### 1) Prognoza oparta na średniej




### 2) Prognozowanie naiwne z użyciem funkcji naive()



### 3) Prognozowanie z użyciem funkcji `snaive()`



### 4) Prognozowanie naiwne z dryfem



Najlepszą metodą w celu prognozy liczby całkowitych szczepień jest zastosowanie tutaj prognozowania naiwnego z dryfem z powodu trendu wielomianowego w szeregu. Nadal nie będzie ona jednak wystarczająco poprawna.